

《深度学习》



深度学习软硬件

内容

深度学习硬件


CPU

GPU

深度学习软件框架

Pytorch


深度学习三要素



深度学习（Deep Learning）作为人工智能的核心技术，已在各个领域取得了卓越的应用成果。其成功的关键，归结于三个重要要素：

- 1. 数据：**高质量的训练数据是深度学习模型的根基，决定了模型的学习能力和泛化能力。
 - 2. 算法：**创新的神经网络和优化技术使得深度学习模型能够从数据中自我学习、进化，解决复杂的任务。
 - 3. 算力：**强大的GPU计算力提供了支持深度学习模型大规模训练的基础，促进了模型训练效率和精准度的飞跃。
-

CPU vs. GPU



CPU

- 擅长：复杂逻辑判断、低延迟串行任务
- 架构：少而精的核心，强大的缓存

解决复杂难题



GPU

- 擅长：海量并行计算、高吞吐量矩阵运算
- 架构：多而简的核心，侧重数据吞吐

高效重复劳动

深度学习的矩阵运算需求，让 GPU 从图形处理跨界成为 AI 计算的核心引擎

CPU vs. GPU



CPU (中央处理器)

计算机的运算和控制核心，执行指令、处理数据，是系统的“大脑”。冯·诺依曼体系结构的核心。

1971年：Intel 4004，首款商用微处理器诞生

80-90年代：x86架构确立，主频竞赛时代开启

2000s：多核时代开启，转向并行计算

2010s+：异构计算兴起，集成AI加速单元



GPU (图形处理器)

最初为加速图形渲染设计，拥有大量并行处理单元，擅长处理大规模并发数据。

1999年：NVIDIA GeForce 256，首提GPU概念

2006年：推出CUDA，开启通用计算(GPGPU)

2012年：AlexNet夺冠，GPU引爆深度学习革命

2017+：Tensor Core出现，成AI算力绝对核心

CPU 基本原理



运算器 (ALU)

执行算术运算（加减乘除）和逻辑运算（与或非），是计算机的“计算器”。



控制器 (CU)

从内存读取指令并译码，指挥计算机各部件协同工作，相当于“指挥官”。



寄存器 (Registers)

CPU内部的高速存储单元，临时存放数据和指令，决定了数据处理的吞吐速度。

指令周期：取指 → 译码 → 执行 → 写回



1. 取指 (Fetch)

从内存中获取下一条指令



2. 译码 (Decode)

解释指令含义，确定操作



3. 执行 (Execute)

由运算器执行具体运算



4. 写回 (Writeback)

将结果写回寄存器或内存

性能关键指标：



时钟频率



核心数量



缓存大小



指令集架构

CPU 发展历史：从单核到异构计算的演进之路



1970s

微处理器诞生

1971年Intel 4004问世，标志着微处理器诞生



1980s-2000s

主频竞赛时代

主频从MHz飙升至GHz，x86架构确立PC和服务器的主要主流架构



2000s后期

多核时代开启

主频遇瓶颈转向多核并行，超线程技术挖掘单核心潜力



2010s至今

异构计算与加速


注重能效比，集成AI加速等专用单元。

主流 CPU 型号



Intel Xeon Scalable

最多 60+ 核心，支持 AVX-512AI 指令集，具备强大的内存扩展能力，是当前数据中心的主流选择。



AMD EPYC (Genoa)

核心密度高，能效比优秀，支持 PCIe5.0 和高带宽内存，在多线程计算性能上极具竞争力。



国产CPU (华为鲲鹏920)


强调自主可控，基于 ARM 架构，生态适配日益完善，在国产化替代和特定应用场景中表现出色。

三大阵营各具特色，共同推动算力基础设施的多元化发展

数据中心 / AI服务器使用的CPU处理器

深度学习中 CPU 功能

数据预处理



负责数据的加载、清洗、格式转换和增强，为GPU准备好“干净”的数据。

任务调度



作为系统的大脑，协调GPU、内存、存储之间的工作，管理计算流程。

轻量级推理



在边缘设备或资源受限的环境中，运行一些小型、轻量级的AI模型。

分布式训练管理




在计算集群中，负责节点间的通信、同步和任务分发，确保高效协作。

CPU 功能1: 数据预处理

-  数据加载与读取：从硬盘或网络存储中加载原始数据（如图像、文本、日志）。
-  数据清洗：处理缺失值、异常值、重复数据，保证数据质量。
-  数据格式转换：将原始数据转换为模型可识别的张量（Tensor）格式。
-  数据增强：通过随机裁剪、翻转等方式扩充数据集，提升泛化能力。
-  特征工程：对结构化数据进行归一化、标准化等处理，提取有效特征。



CPU优势：此阶段涉及复杂逻辑判断和文件I/O操作，CPU的复杂指令集和强大单核性能能高效完成这些工作。



AI DATA PROCESSING

CPU 功能2: 任务调度



协调计算资源

管理系统资源分配，决定任务在CPU与GPU间的执行时机，平衡负载。



内存管理

负责RAM与VRAM间的数据搬运，利用梯度检查点等技术解决显存瓶颈。



流程控制

执行训练循环逻辑，管理Epoch/Batch、学习率调度及回调函数调用。



I/O 操作处理

处理硬盘读写与网络交互，如模型参数的周期性保存与日志记录。



CPU 核心优势：这些任务依赖强大的逻辑判断、流程控制能力以及对系统资源的全局视野，这正是CPU作为“调度大脑”的不可替代性。

CPU 功能3: 轻量级推理



端侧 AI 主力
无处不在的智能终端



典型应用场景

智能手机语音助手、人脸解锁、拍照优化；智能家居本地控制；工业传感器实时数据分析。



轻量级模型特点


体积小巧（几MB到几十MB）、对延迟要求极高、对设备功耗极度敏感，需高度优化。



CPU 核心优势

普及率高（无处不在）、功耗可控（优于独立AI芯片）、部署便捷（成熟软件生态支持）。

CPU 功能4: 分布式训练管理



网络协同架构



节点通信：高速信息交换

负责节点间高速网络通信（如InfiniBand），交换梯度、参数等关键信息，保障数据流转。



同步与聚合：AllReduce操作中枢

收集不同GPU的计算结果，执行同步和聚合操作，确保数据并行与模型并行的一致性。



集群管理：稳定性保障

监控节点健康与负载，在故障时进行任务重分配，维持整个训练集群的稳定运行。



CPU核心优势：支撑高网络I/O吞吐与复杂同步逻辑，是实现大规模分布式训练的关键算力底座。

CPU 选型：按需选择



轻量级任务

典型场景：

算法原型验证、小数据集实验

推荐型号：

Intel Core i7/i9

AMD Ryzen 7/9

核心需求：

8-16核，高频



中等规模任务

典型场景：

常规数据预处理、模型训练辅助

推荐型号：

Intel Xeon Silver/Gold

AMD EPYC 7003

核心需求：

16-32核，大内存



大规模任务

典型场景：

分布式训练节点、超算中心

推荐型号：

Intel Xeon Platinum

AMD EPYC 9004

核心需求：

32核以上，高扩展性

按需选择硬件配置，平衡性能与成本

GPU 发展历史



1990s

图形加速卡时代

最初的GPU仅作为3D图形加速卡，功能单一，如3dfx Voodoo，专注于图形渲染。



1999

GPU概念诞生

NVIDIA发布GeForce 256，首次提出“GPU”概念，集成了几何变换与光照引擎。



2006

GPGPU革命

推出CUDA编程模型，打破图形限制，GPU开始用于通用科学计算。



2012

深度学习引爆

AlexNet夺冠ImageNet，证明GPU并行计算是训练深度神经网络的完美工具。



2017+

AI专用硬件

引入Tensor Core，Volta/Ampere架构强化算力，GPU成为AI时代核心引擎。

“GPU的发展史，是一部从图形渲染的配角，进化为人工智能算力核心的史诗。”

GPU：深度学习的“性能引擎”



架构优势：并行计算核心

CUDA核心负责通用计算，Tensor Core专门加速矩阵运算，两者协同工作，效率倍增。



显存技术：HBM高带宽吞吐

采用HBM技术解决带宽瓶颈，保证海量数据的高速吞吐，满足深度学习的算力需求。



生态系统：CUDA平台优势


拥有完善的软件生态，主流深度学习框架均对其深度优化，开发者支持度极高。



应用落地：从训练到推理

不仅在模型训练阶段提供算力，也在边缘计算和云端推理中发挥着关键作用。

性能飞跃：ResNet-50 模型训练效率对比



高端 CPU

数天 (Days)



V100 GPU

数小时 (Hours)

速度提升 > 50x

GPU工作原理



核心组成架构

- 流式多处理器: 计算核心, 包含CUDA核心与Tensor Core, 是执行计算的“车间”。
- 显存控制器: 管理GDDR6等高速显存, 保障数据的高效吞吐。
- 总线接口: 负责与CPU和系统内存的通信连接。



并行计算原理

- SIMT 架构: 单指令多线程, 一个指令同时驱动多个线程执行, 最大化并行效率。
- 线程束 (Warp): 调度基本单位 (通常32线程), 确保硬件资源被充分利用。
- 细粒度任务: 擅长像素渲染、矩阵运算等重复度高的计算。



CPU vs GPU

- CPU 角色: “全能型选手”, 侧重复杂逻辑控制和串行任务处理。
- GPU 角色: “并行专家”, 拥有海量核心, 擅长将简单任务重复执行数万次。
- 协同工作: CPU负责指挥, GPU负责大规模数据的暴力计算。



总结: GPU通过海量的计算核心和独特的SIMT架构, 将计算任务分解为细粒度的并行子任务, 从而在处理图形渲染、深度学习等大规模并行计算时展现出超越CPU的惊人性能。

GPU定位

消费级 GPU (GeForce RTX)

定位：面向游戏玩家、内容创作者及个人AI研究者。

代表型号：

RTX 3090/3090 Ti：大显存，早期AI热门选择

RTX 4090：单精度性能，支持DLSS 3与AI算力

核心特点：高性价比，兼顾图形渲染与轻量级AI计算

数据中心 GPU (Tesla/A系列)

定位：面向企业与科研机构，支撑大规模AI训练与HPC。

代表型号：

V100/A100：AI大模型时代主流，兼顾训练与推理

H100：Hopper架构旗舰，专为千亿级大模型优化

核心特点：极致的浮点算力，超大显存与高可靠性

双轨并行策略：消费级市场普及AI体验，数据中心市场驱动算力革命

数据中心GPU：Volta到Hopper架构解析

Tesla V100 (Volta)

Tensor Core：第一代 (FP16/INT8)

AI算力 (FP16)：125 TFLOPS

显存配置：16/32GB

显存带宽：900 GB/s

关键特性：首次引入Tensor Core，开启AI加速时代

A100 (Ampere)

Tensor Core：第三代 (支持稀疏计算)

AI算力 (FP16)：312 TFLOPS

显存配置：40/80GB

显存带宽：2039 GB/s

关键特性：MIG多实例GPU，引入结构化稀疏性

H100 (Hopper)

Tensor Core：第四代 (Transformer引擎)

AI算力 (FP8)：2000+ TFLOPS

显存配置：80GB

显存带宽：3350 GB/s

关键特性：原生支持FP8精度，专为千亿参数大模型优化

核心算力飞跃总结：

从V100到H100，不仅实现了AI算力的数十倍增长，更通过对FP8新数据类型和Transformer引擎的原生支持，突破了大模型训练的算力瓶颈，成为支撑万亿参数时代的核心动力。


大模型时代 GPU 主流型号



A100

Ampere 架构


市场中坚力量，性能与成本平衡。支持MIG多实例技术，适合中大型模型训练与推理。



H100

Hopper 架构


旗舰级训练芯片，引入FP8精度与Transformer引擎，是训练千亿参数大模型的首选。



H200

Hopper 架构

拥有141GB HBM3e显存，专为处理超大规模模型和超长上下文场景设计。



B100

Blackwell 架构

下一代架构，将带来更高的能效比和算力，是未来AI计算的新标杆。

从Ampere到Blackwell，NVIDIA持续引领AI算力的指数级飞跃

GPU CUDA平台与生态：NVIDIA的“护城河”



核心组件

CUDA Toolkit

包含编译器、调试器、性能分析器等全套开发工具链。

CUDA Runtime

提供在GPU上执行计算的核心API接口。



库与框架

高性能基础库

cuBLAS(线性代数)、cuFFT(傅里叶变换)、cuDNN(深度学习)。

主流AI框架

TensorFlow, PyTorch等深度集成, 优化极致性能。



开发者工具

Nsight系列

强大的系统与计算性能分析器, 精准定位瓶颈。

NGC云平台

提供预训练模型、容器和行业解决方案。




生态壁垒与护城河：CUDA拥有最广泛的开发者社区和最完善的软件支持，极高的技术壁垒使得NVIDIA在GPU通用计算市场占据绝对主导地位。

GPU 国产自主可控的AI算力



华为昇腾910B/C

性能对标NVIDIA A100/H100，拥有完整的“芯片-框架-服务器”全栈生态，是国产AI芯片的领军者。



寒武纪思元590

专注于云端训练和推理，采用先进的Chiplet技术，在智能计算卡市场表现突出。

计算机视觉-任务类



图像分类 (ResNet)

中等显存需求，主要瓶颈在于算力性能。

推荐配置

RTX 4060 Ti / 4070 / 4090



目标检测 (YOLO)

通常需要处理更高分辨率输入和多尺度特征图，因此显存开销更高。

推荐配置

RTX 4080 / 4090



图像生成 (SD)

极高显存需求，极度依赖 Tensor Core 性能。

推荐配置

推理/个人实验: RTX 4090
大规模训练/科研平台: A100/H100

从分类到生成，任务复杂度提升导致显存与算力需求显著增长。

自然语言处理类-任务



轻量级模型 (110M)

需求：单卡中高端GPU即可满足推理与微调需求。

推荐：RTX 3090 / A10



大语言模型 (7B/13B)

需求：显存敏感，通常需要多卡并行计算。

推荐：2×A100 (40GB) / 2×H100



超大模型 (70B+/GPT级)

需求：顶级集群，依赖高速NVLink互联技术。

推荐：8×A100 (80GB) / H100集群



随着模型规模增加，对显存容量、带宽和算力的需求快速增长。

硬件选择策略



1. 确定任务类型

明确计算机视觉、NLP或强化学习等具体应用场景。



2. 评估模型规模

判断是小模型、中等模型还是大模型/超大模型。



3. 考虑预算与成本

在性能需求和价格成本之间找到最佳平衡点。



4. 决定硬件类型

决定以CPU为主、以GPU为主，或是选择国产方案。



5. 确定具体配置

确定CPU/GPU具体型号、数量及配套内存存储。

遵循此流程可快速、科学地制定最适合的硬件方案，避免盲目跟风或资源浪费。

内容

深度学习硬件

CPU

GPU

深度学习软件框架

Pytorch

Pytorch 安装 <https://pytorch.org/>

PyTorch

Learn ▾Community ▾Projects ▾Docs ▾Blog & News ▾About ▾[JOIN](#)

Install PyTorch

Select your preferences and run the install command. Stable represents the most currently tested and supported version of PyTorch. This should be suitable for many users. Preview is available if you want the latest, not fully tested and supported, builds that are generated nightly. Please ensure that you have **met the prerequisites below (e.g., numpy)**, depending on your package manager. You can also [install previous versions of PyTorch](#). Note that LibTorch is only available for C++.

NOTE: Latest Stable PyTorch requires Python 3.10 or later.

PyTorch Build	Stable (2.10.0)	Preview (Nightly)		
Your OS	Linux	Mac	Windows	
Package	Pip	LibTorch	Source	
Language	Python	C++ / Java		
Compute Platform	CUDA 12.6	CUDA 12.8	CUDA 13.0	ROCm 7.1
	CPU			
Run this Command:	<pre>pip3 install torch torchvision --index-url https://download.pytorch.org/whl/cu126</pre>			

Previous versions of PyTorch

Quick Start With Cloud Partners

Get up and running with PyTorch quickly through popular cloud platforms and machine learning services.

[Amazon Web Services](#)

[Google Cloud Platform](#)

[Microsoft Azure](#)

[Lightning Studios](#)

Pytorch



框架概览

什么是PyTorch，它的起源与优势



核心基石

张量 (Tensor) 与自动求导 (Autograd)



模型构建

使用nn.Module构建神经网络



数据处理

Dataset与DataLoader详解



训练流程

损失函数、优化器与模型训练循环



模型部署

模型的保存、加载与ONNX导出



高级特性

自定义模块、分布式训练与模型微调

Pytorch

起源与定位

由Facebook AI Research (FAIR) 团队开发，于2016年首次发布。

主要面向两类受众：

替代NumPy以使用GPU计算能力
提供灵活性与速度的深度学习研究平台

核心优势



动态计算图 (Dynamic Graph)

定义与执行同步，调试方便，支持动态控制流。



Pythonic 设计

深度集成Python生态，API直观，易于学习使用。



强大的社区与生态

庞大开发者社区，丰富的第三方库和教程资源。



高效的性能

C++底层实现，支持多GPU和分布式训练。

01:核心基石：张量（Tensor）与自动求导（Autograd）

张量 (Tensor): PyTorch的基本数据结构



什么是张量?

- 多维数组: PyTorch中存储和操作数据的核心结构。
- GPU加速: 可视为NumPy数组的GPU版本, 支持异构计算。



常用创建方法

- 基础: `torch.tensor(data) / zeros() / ones()`
- 随机: `torch.randn(shape)`(正态分布)
- 转换: `torch.from_numpy(ndarray)`



基本操作与特性

算术运算

`+` `-` `*` `/` `@` (矩阵乘)

索引切片

类似 Python/NumPy

形状变换

`view()` / `reshape()` / `permute()`

设备移动

`.to('cuda')` / `.to('cpu')`

掌握张量操作是构建深度学习模型的第一步, 它是连接算法与硬件加速的桥梁。

自动求导 (Autograd): 神经网络训练的核心

前向传播 (Forward Pass)

动态构建计算图，记录张量运算的每一步骤与依赖关系，为反向传播打下基础。

反向传播 (Backward Pass)

调用 `.backward()` 方法，从结果张量出发，利用链式法则自动计算所有叶子节点的梯度。

关键属性与方法解析

`requires_grad`

设为 `True` 时，表明需要对该张量进行梯度追踪。

`.grad`

存储反向传播计算得到的梯度值，初始为 `None`。

`.backward()`

触发反向传播过程，计算所有相关张量的梯度。

`.detach()`

将张量从计算图中分离，停止梯度追踪，常用于冻结参数。

总结：Autograd 机制让我们无需手动推导复杂的梯度公式，只需专注于模型结构的定义，极大地提升了开发效率。

张量的高级操作与特性

广播机制

自动扩展不同形状张量，使其兼容运算，无需复制数据。

```
a = torch.ones(3, 1)
b = torch.ones(1, 4)
c = a + b# (3, 4)
```

高级索引

使用列表、张量或布尔值进行灵活筛选，实现复杂数据提取。

```
x = torch.randn(3, 4)
mask = x > 0
res = x[mask]# 筛选正数
```

内存布局

存储顺序影响效率。使用 `contiguous()` 转换为连续存储。

```
x = torch.randn(4, 3).t()
print(x.is_contiguous())
x = x.contiguous()# 转为连续
```

💡 核心价值：掌握这些特性能显著提升代码的简洁性与运行效率，是构建高性能深度学习模型的基础。

02:模型构建：使用 `nn.Module` 构建神经网络

从 Tensor 计算到模块化封装，掌握 PyTorch 中最核心的神经网络构建基类，实现灵活高效的模型定义与管理。

nn.Module: 构建模型的基础类



核心简介

PyTorch中所有神经网络模块的基类，自定义模型必须继承该类并实现核心方法。



`__init__(self)`

构造函数，用于定义网络的层（如Conv2d, Linear）和参数。



`forward(self, x)`

定义前向传播逻辑，数据如何流经网络层。调用时使用 `model(x)` 而非直接调用 `forward`。

代码示例: SimpleNet

```
Class SimpleNet(nn.Module):  
    def __init__(self):  
        super(SimpleNet, self).__init__()  
        self.conv1 = nn.Conv2d(1, 10, 5)  
        self.fc1 = nn.Linear(10*12*12, 10)  
    def forward(self, x):  
        x = F.relu(F.max_pool2d(self.conv1(x), 2))  
        # ... 省略展平与全连接层 ...  
        return x
```



调用模型时，请使用 `model(x)`，PyTorch会自动调用 `forward` 方法。

使用nn.Module实现多层感知机 (MLP)

```
class SimpleMLP(nn.Module):
    """简单MLP：输入784维，输出10维"""
    def __init__(self, input_size=784):
        super(SimpleMLP, self).__init__()
        # 1. 定义网络层结构
        self.fc1 = nn.Linear(input_size, 128)
        self.fc2 = nn.Linear(128, 10)

    def forward(self, x):
        # 2. 定义数据流向: 展平 -> 线性 -> 激活 -> 输出
        x = x.view(x.size(0), -1)
        x = F.relu(self.fc1(x))
        return self.fc2(x)
```

结构定义 (__init__)

在构造函数中定义网络的静态层结构。这里我们使用了两个全连接层 (nn.Linear) 来搭建网络骨架。

数据流向 (forward)

定义数据如何通过网络。首先将28x28图像展平为784维向量，经过隐藏层和ReLU激活函数，最后输出10维分类结果。



模型应用场景：该结构是深度学习的基础，可直接用于MNIST手写数字识别任务。通过继承nn.Module，我们获得了PyTorch自动求导、设备迁移等强大功能。

nn.Module实现卷积神经网络(CNN)

```
class SimpleCNN(nn.Module):
    def __init__(self, num_classes=10):
        super(SimpleCNN, self).__init__()
        # 卷积层与池化层, 假设输入图像尺寸为32*32*1
        self.conv1 = nn.Conv2d(1, 6, 5) # 1->6通道, 5x5核
        self.pool1 = nn.MaxPool2d(2, 2) # 2x2池化, 步幅2
        self.conv2 = nn.Conv2d(6, 16, 5)
        self.pool2 = nn.MaxPool2d(2, 2)
        # 全连接层
        self.fc1 = nn.Linear(16*5*5, 120)
        self.fc2 = nn.Linear(120, 84)
        self.fc3 = nn.Linear(84, num_classes)
    def forward(self, x):
        x = self.pool1(F.relu(self.conv1(x)))
        x = self.pool2(F.relu(self.conv2(x)))
        x = x.view(x.size(0), -1) # 展平特征图
        x = F.relu(self.fc1(x))
        x = F.relu(self.fc2(x))
        return self.fc3(x)
```



卷积层 (Conv2d)

使用 nn.Conv2d 提取图像的局部特征, 捕捉边缘、纹理等信息, 是CNN的核心。



池化层 (MaxPool2d)

通过下采样降低特征图维度, 减少参数量, 防止过拟合, 同时保留主要特征。



全连接层 (Linear)

将提取的特征展平为一维向量, 通过多层线性变换完成最终的分类任务。



核心逻辑: 卷积提取特征 → 池化降维 → 全连接分类

常用层与容器：快速搭建复杂网络

常用网络层 (Layers)



卷积层 (Conv2d/3d)

提取空间特征，计算机视觉核心组件。



池化层 (Max/Avg Pool)

下采样减少参数，防止过拟合。



全连接层 (Linear)

特征映射到指定维度，常用于分类任务。



循环层 (LSTM/GRU)

处理序列数据，如文本、时间序列。



激活函数 (ReLU/Sigmoid)

引入非线性，增加模型表达能力。

常用容器 (Containers)



nn.Sequential- 按顺序堆叠层，适合线性网络。

```
model = nn.Sequential(  
    nn.Conv2d(1, 20, 5), nn.ReLU(),  
    nn.Conv2d(20, 64, 5), nn.ReLU()  
)
```



nn.ModuleList

像Python列表一样存储子模块，支持索引和迭代。



nn.ModuleDict

像Python字典一样存储子模块，通过键值对访问。

PyTorch 提供了丰富的模块化组件，让网络构建更加高效灵活。

模型初始化与参数共享

⚙️ 参数初始化的重要性

- 合适的初始化可加速收敛，避免梯度消失或爆炸。
- PyTorch层有默认初始化，但复杂网络常需自定义策略。

🔄 网络参数共享机制

- 核心思想：在网络中多次复用同一个层实例。
- 优势：大幅减少参数量，防止过拟合，适用于特定结构。

📄 自定义初始化 (torch.nn.init)

```
import torch.nn.init as init
# 在__init__中初始化
init.xavier_uniform_(self.conv1.weight)# 权重
init.constant_(self.fc1.bias, 0.1)# 偏置
```

📄 实现参数共享 (Code)

```
# 定义共享层实例
shared_linear = nn.Linear(10, 10)
# 多次传入同一个对象
net = nn.Sequential(shared_linear, shared_linear)
```

03:数据处理: Dataset与DataLoader详解

DATA PROCESSING IN PYTORCH

数据变换 (Transforms): 数据增强与预处理



Transforms 的核心作用

- **数据预处理**: 将 PIL 图像转为张量、归一化像素值。
- **数据增强**: 随机裁剪、翻转等操作, 增加数据多样性, 防止过拟合。



常用变换操作

ToTensor(): 转换为张量并归一化至 $[0, 1]$ 。
Normalize(): 标准化张量, 设置均值和标准差。
RandomCrop(): 随机裁剪图像, 增加鲁棒性。
RandomHorizontalFlip(): 随机水平翻转。



使用 Compose 组合变换

```
from torchvision import transforms
import torch
# 训练集变换 (含增强)
train_transform= transforms.Compose([
    transforms.RandomResizedCrop(224),
    transforms.RandomHorizontalFlip(),
    transforms.ToTensor(),
    transforms.Normalize(mean=[0.485, ...], std=[0.229, ...])
])
# 测试集变换 (仅预处理)
val_transform= transforms.Compose([...])
```



重要提示: 数据增强操作 (如随机裁剪、翻转) 仅应在训练阶段使用, 测试阶段应避免引入随机性。

Dataset: 自定义数据的抽象表示



核心概念

PyTorch中表示数据集的抽象类，所有自定义数据集都应继承此类，实现标准化接口。



`__len__(self)`

返回数据集的总样本数，决定了数据加载器的迭代次数上限。



`__getitem__(self, idx)`

根据索引 `idx` 加载并返回单个样本（通常包含数据和标签）。



提示：PyTorch 内置了 MNIST, CIFAR-10 等常用数据集，可直接调用。

代码实现示例

```
from torch.utils.data import Dataset
class MyDataset(Dataset):
    def __init__(self, data, labels):
        self.data = data
        self.labels = labels

    def __len__(self):
        return len(self.data)

    def __getitem__(self, idx):
        sample = self.data[idx]
        label = self.labels[idx]
        return sample, label
```

DataLoader: 高效加载与批量处理数据

PyTorch 核心数据加载工具，封装 Dataset 对象，提供批量加载、打乱与多线程加速功能。

核心参数解析



dataset: 要加载的 Dataset 对象实例



batch_size: 每个批次包含的样本数量 (如 32, 64)



shuffle: 是否在每个 epoch 开始时打乱数据顺序



num_workers: 加载数据的子进程数，用于加速读取

代码示例

```
from torch.utils.data import DataLoader
# 假设已有 MyDataset 实例
my_dataset= MyDataset(data, labels)
loader= DataLoader(
    dataset=my_dataset, batch_size=32,
    shuffle=True, num_workers=4
)
for data, labels in loader:
    train_step(data, labels)# 训练逻辑
```

04: 训练流程：损失函数、优化器与模型训练循环

TRAINING PROCESS & MODEL OPTIMIZATION

损失函数与优化器：模型学习的“方向盘”与“发动机”

损失函数 (Loss Function)

衡量预测与真实标签的差异，是模型优化的目标（方向盘）。

nn.MSELoss：均方误差，用于回归任务。

nn.CrossEntropyLoss：交叉熵，用于多分类，含Softmax。

nn.NLLLoss：负对数似然，配合LogSoftmax使用。

优化器 (Optimizer)

根据梯度更新模型参数，最小化损失（发动机）。

SGD：随机梯度下降，基础算法，可带动量。

Adam：结合动量与自适应学习率，收敛快。

RMSprop：另一种自适应学习率优化算法。

代码示例：定义损失函数与优化器

```
criterion = nn.CrossEntropyLoss()
```

```
optimizer = torch.optim.Adam(model.parameters(), lr=0.001)
```

完整的训练循环：训练与验证

训练阶段 (Training Phase)

- 开启训练模式：`model.train()`
- 核心三部曲：
- `optimizer.zero_grad()`
- `loss.backward()`
- `optimizer.step()`
- 目的：通过梯度下降不断更新模型参数，降低损失

验证阶段 (Validation Phase)

- 开启评估模式：`model.eval()`
- 上下文管理器：`with torch.no_grad(): ...`
- 目的：评估模型泛化能力，防止过拟合，不更新参数。

PyTorch 标准实现代码示例

```
# 外层循环：Epoch 迭代
for epoch in range(num_epochs):
    model.train()# 训练模式开启
    for inputs, labels in train_loader:
        optimizer.zero_grad()
        outputs = model(inputs)# 前向传播
        loss = criterion(outputs, labels)
        loss.backward()# 反向传播
        optimizer.step()# 更新参数

    model.eval()# 切换为评估模式
    with torch.no_grad():# 停止梯度计算
        for inputs, labels in val_loader:
            outputs = model(inputs)
            val_accuracy = val_metric(outputs, labels)
```

 **关键点：**不要忘记在训练和验证阶段切换模型模式，这对 Dropout 和 BatchNorm 层的行为至关重要。

学习率调度 (Learning Rate Scheduling)



核心作用

- 解决固定学习率难以收敛至最优解的问题。
- 动态调整学习率，前期大步搜索，后期精细微调。
- 帮助模型跳出局部最优，提升泛化能力。



常用调度器

StepLR: 每隔固定epoch乘以gamma衰减。

ReduceLROnPlateau: 监控验证集性能，停滞时衰减。

CosineAnnealingLR: 学习率按余弦函数周期性变化。



StepLR 使用示例

```
scheduler= StepLR(optimizer, step_size=7,  
gamma=0.1)  
# 训练循环中 (每个Epoch后)  
optimizer.step()  
scheduler.step()
```



ReduceLROnPlateau 使用示例

```
scheduler= ReduceLROnPlateau(opt, 'min')  
# 验证后 (传入验证损失)  
val_loss = validate(...)  
scheduler.step(val_loss)
```



最佳实践: 优先尝试 ReduceLROnPlateau，它能根据验证集表现智能调整，避免学习率过早衰减或衰减不足。

05: 模型部署：模型的保存、加载与ONNX导出



模型保存

利用 `state_dict` 保存权重，灵活存储训练成果



模型加载

快速恢复模型状态，支持断点续训与推理



ONNX 导出

统一模型格式，实现跨框架、跨平台高效部署

模型的保存与加载：保存训练成果



保存整个模型

保存模型的结构和参数，方便直接加载使用，但文件体积较大。

```
# 保存
torch.save(model, 'm.pth')
# 加载
model = torch.load('m.pth')
```



只保存参数 (推荐)

仅保存状态字典(state_dict)，体积小，灵活度高，生产环境首选。

```
# 保存
torch.save(m.state_dict(), 'd.pth')
# 加载
m.load_state_dict(torch.load('d.pth'))
```



保存检查点

保存训练进度快照（含epoch、loss、优化器状态），便于中断后恢复。

```
# 保存字典
torch.save({
    'epoch': epoch,
    'state_dict': m.state_dict()}, 'ckpt.pth')
```



最佳实践：在大多数场景下，强烈推荐使用“只保存参数”的方式，因为它在保证功能完整的同时，提供了最小的文件体积和最大的部署灵活性。

模型优化：使用TorchScript



核心概念

- PyTorch的中间表示(IR)，将动态Python代码转换为静态序列化格式。
- 脱离Python环境运行，减少解释器开销，显著提升推理性能。



核心优势



性能优化

静态图编译优化，降低运行时延迟。

。



跨平台部署

支持C++/Java等非Python环境部署。



互补ONNX

PyTorch生态部署的重要补充方案。



转换示例 (Tracing)

```
import torch
model = models.resnet18().eval()
inp = torch.rand(1, 3, 224, 224)
# 跟踪转换
traced = torch.jit.trace(model, inp)
traced.save("model.pt")
```

TorchScript 提供了动态图的灵活性与静态图的高性能之间的完美平衡，是生产环境部署的优选方案。

ONNX导出：跨平台部署的桥梁

什么是 ONNX?

ONNX (Open Neural Network Exchange) 是开放的神经网络模型格式标准。它打破框架壁垒，允许 PyTorch、TensorFlow 等不同框架之间互相转换模型。

核心应用场景

作为中间格式，连接训练与部署。导出后可无缝接入 TensorRT、ONNX Runtime、OpenVINO 等高性能推理引擎，实现跨平台高效推理。

PyTorch 导出 ONNX 代码示例

```
import torch
dummy_input = torch.randn(1,1,28,28)
torch.onnx.export(
    model, dummy_input, "model.onnx",
    export_params=True, opset_version=11,
    input_names=['input'], output_names=['output']
)
```

 **总结：**ONNX 不仅是格式的转换，更是打通了从算法研究到工程落地的“最后一公里”。

06 特性：自定义模块、分布式训练与模型微调

其他特性



自定义层/模块

当PyTorch提供的预定义层无法满足需求时，可继承nn.Module自定义复杂层或模块，实现特定运算逻辑。



模型微调 (Transfer Learning)

利用预训练模型（如ResNet）作为起点，在新数据集上微调，快速获得效果，适用于小样本学习。



分布式训练 (DDP)

利用DistributedDataParallel在多GPU或多机上进行分布式训练，显著加速训练过程。



混合精度训练 (Amp)

使用torch.cuda.amp实现自动混合精度，在保证精度前提下利用FP16加速并减少内存占用。