

《深度学习》




循环神经网络


前馈网络

连接存在层与层之间，每层的节点之间是无连接的（无循环）

输入和输出的维数都是固定的，不能任意改变。无法处理变长的序列数据。




(a) 全连接层



(b) 卷积层

前馈网络

假设每次输入都是独立的，也就是说每次网络的输出只依赖于当前的输入。



前馈网络

全连接神经网络和卷积神经网络的特点

- 擅长处理单个输入样本。
- 通常假设各个输入之间彼此独立，难以直接建模前后顺序关系。

序列任务的需求

- 许多实际任务中，数据之间具有明显的时序或上下文关联。
- 在自然语言处理中，需要结合整个词序列来理解句子的含义。
- 在视频分析中，需要结合连续帧的信息来理解动作和事件的发展过程。


如何给网络增加记忆能力？

延时神经网络（Time Delay Neural Network, TDNN）

建立一个额外的延时单元，用来存储网络的历史信息（可以包括输入、输出、隐状态等）

$$\mathbf{h}_t^{(l)} = f(\mathbf{h}_t^{(l-1)}, \mathbf{h}_{t-1}^{(l-1)}, \dots, \mathbf{h}_{t-K}^{(l-1)})$$

这样，前馈网络就具有了短期记忆的能力。



https://www.researchgate.net/publication/12314435_Neural_system_identification_model_of_human_sound_localization

如何给网络增加记忆能力？

自回归模型（Autoregressive Model, AR）

一类时间序列模型，用变量 y_t 的历史信息来预测自己

$$y_t = w_0 + \sum_{k=1}^K w_k y_{t-k} + \epsilon_t$$

$\epsilon_t \sim N(0, \sigma^2)$ 为第 t 个时刻的噪声

有外部输入的非线性自回归模型

$$y_t = f(\mathbf{x}_t, \mathbf{x}_{t-1}, \dots, \mathbf{x}_{t-K_x}, y_{t-1}, y_{t-2}, \dots, y_{t-K_y})$$


其中 $f(\cdot)$ 表示非线性函数，可以是一个前馈网络， K_x 和 K_y 为超参数。

循环神经网络 (Recurrent Neural Network , RNN)

循环神经网络通过使用带自反馈的神经元，能够处理任意长度的时序数据。

$$\mathbf{h}_t = f(\mathbf{h}_{t-1}, \mathbf{x}_t)$$



活性值
状态



循环神经网络比前馈神经网络更加符合生物神经网络的结构。

循环神经网络已经被广泛应用于语音识别、语言模型以及自然语言生成等任务上

按时间展开



如果我们把每个时刻的状态都看作前馈神经网络的一层，循环神经网络可以看作在时间维度上权值共享的神经网络。

简单循环网络 (Simple Recurrent Network , SRN)

简单循环网络 (Simple Recurrent Network, SRN) 是一个非常简单的循环神经网络, 只有一个隐藏层的神经网络. 在一个两层的前馈神经网络中, 连接存在相邻的层与层之间, 隐藏层的节点之间是无连接的. 而简单循环网络增加了从隐藏层到隐藏层的反馈连接。

令向量 $\mathbf{x}_t \in \mathbb{R}^M$ 表示在时刻 t 时网络的输入, $\mathbf{h}_t \in \mathbb{R}^D$ 表示隐藏层状态 (即隐藏层神经元活性值), 则 $\mathbf{h}_t$ 不仅和当前时刻的输入 $\mathbf{x}_t$ 相关, 也和上一个时刻的隐藏层状态 $\mathbf{h}_{t-1}$ 相关. 简单循环网络在时刻 t 的更新公式为

$$\mathbf{z}_t = \mathbf{U}\mathbf{h}_{t-1} + \mathbf{W}\mathbf{x}_t + \mathbf{b},$$

$$\mathbf{h}_t = f(\mathbf{z}_t),$$

其中 $\mathbf{z}_t$ 为隐藏层的净输入, $\mathbf{U} \in \mathbb{R}^{D \times D}$ 为状态-状态权重矩阵, $\mathbf{W} \in \mathbb{R}^{D \times M}$ 为状态-输入权重矩阵, $\mathbf{b} \in \mathbb{R}^D$ 为偏置向量, $f(\cdot)$ 是非线性激活函数, 通常为 Logistic 函数或 Tanh 函数. 公式 (6.5) 和公式 (6.6) 也经常直接写为

$$\mathbf{h}_t = f(\mathbf{U}\mathbf{h}_{t-1} + \mathbf{W}\mathbf{x}_t + \mathbf{b}).$$

简单循环网络 (Simple Recurrent Network , SRN)

状态更新:

$$\mathbf{h}_t = f(\mathbf{U}\mathbf{h}_{t-1} + \mathbf{W}\mathbf{x}_t + \mathbf{b})$$

一个完全连接的循环网络是任何非线性动力系统的近似器。

定理 6.1 – 循环神经网络的通用近似定理 [Haykin, 2009]: 如果一个完全连接的循环神经网络有足够数量的 sigmoid 型隐藏神经元, 它可以以任意的准确率去近似任何一个非线性动力系统


$$\mathbf{s}_t = g(\mathbf{s}_{t-1}, \mathbf{x}_t), \quad (6.10)$$

$$\mathbf{y}_t = o(\mathbf{s}_t), \quad (6.11)$$

其中 $\mathbf{s}_t$ 为每个时刻的隐状态, $\mathbf{x}_t$ 是外部输入, $g(\cdot)$ 是可测的状态转换函数, $o(\cdot)$ 是连续输出函数, 并且对状态空间的紧致性没有限制.


序列建模 Many-to-One模型

在文本分类中，输入数据为单词的序列，输出为该文本的类别。




序列到类别


情感分类



Many-to-One模型




(a) 正常模式



(b) 按时间进行平均采样模式


序列建模 One-to-Many模型

输入为一张图片，输出为图片的文字描述




序列建模 Many-to-Many模型

输入和输出的序列个数相同，如输入为视频序列，输出为每一帧对应的标签




中文分词



信息抽取(Information Extraction, IE)


从无结构的文本中抽取结构化的信息，形成知识

小米创始人雷军表示，该公司2015年营收达到780亿元人民币，较2014年的743亿元人民币增长了5%。




序列建模 Many-to-Many模型

输入和输出的序列个数不同，如机器翻译中，源语言和目标语言的 句子往往并没有相同的长度。下述模型又名seq2seq模型。




序列到序列

机器翻译




序列建模 形式汇总


one to many




many to one



many to many




many to many




长程依赖问题

RNN 的长处之一是它可以利用先前的信息到当前的任务上，尤其当相关的信息和 预测的词之间的间隔较小时效果明显。



长程依赖问题

然而在间隔不断增大时，RNN 会丧失学习到连接如此远的信息的能力。



参数学习

给定一个训练样本 $(\mathbf{x}, \mathbf{y})$, 其中

$\mathbf{x} = (x_1, \dots, x_T)$ 为长度是 T 的输入序列,

$\mathbf{y} = (y_1, \dots, y_T)$ 是长度为 T 的标签序列。

时刻 t 的瞬时损失函数为

$$\mathcal{L}_t = \mathcal{L}(\mathbf{y}_t, g(\mathbf{h}_t)),$$


总损失函数

$$\mathcal{L} = \sum_{t=1}^T \mathcal{L}_t.$$

参数学习

随时间反向传播 (BackPropagation Through Time, BPTT) 算法的主要思想是通过类似前馈神经网络的误差反向传播算法来计算梯度。


BPTT算法将循环神经网络看作一个展开的多层前馈网络，其中“每一层”对应循环网络中的“每个时刻”这样，循环神经网络就可以按照前馈网络中的反向传播算法计算参数梯度。在“展开”的前馈网络中，所有层的参数是共享的，因此参数的真实梯度是所有“展开层”的参数梯度之和。



梯度

随时间反向传播算法

$$\mathbf{h}_{t+1} = f(\mathbf{z}_{t+1}) = f(U\mathbf{h}_t + W\mathbf{x}_{t+1} + \mathbf{b})$$



$$\frac{\partial \mathcal{L}}{\partial U} = \sum_{t=1}^T \sum_{k=1}^t \delta_{t,k} \mathbf{h}_{k-1}^T$$

$$\delta_{t,k} = \prod_{\tau=k}^{t-1} \left(\text{diag}(f'(\mathbf{z}_{\tau})) U^T \right) \delta_{t,t}$$

$\delta_{t,k}$ 为第 t 时刻的损失对第 k 步隐藏神经元的净输入 $\mathbf{z}_k$ 的导数

RNN梯度

在循环神经网络中，隐藏状态会不断递推

$$h_t = f(Uh_{t-1} + Wx_t + b)$$

这意味着，某一时刻的损失对更早时刻参数的梯度，要通过很多个时间步一路反向传回来。所以梯度本质上会变成很多项矩阵的连乘积。

$$\delta_{t,k} = \prod_{\tau=k}^{t-1} (\text{diag}(f'(z_\tau))U^T) \delta_{t,t}$$

也就是说，梯度在从时刻 t 传到时刻 k 时，会不断乘上：

循环权重矩阵 U^T

激活函数导数项 $\text{diag}(f'(z_\tau))$

RNN梯度消失

如果这串连乘中，每一步的“放缩系数”都偏小，那么乘很多次后就会越来越小，最后接近 0。

更直观地说：

- 若 $\|U\| < 1$ 或主特征值较小
 - 且激活函数导数 $f'(z)$ 通常也小于 1
- 那么多步相乘后：

$$\|\delta_{t,k}\| \rightarrow 0$$

结果

早期时刻的参数几乎收不到误差信号，模型就学不到远距离依赖。

所以网络通常只能记住最近几步的信息，只能学习到短周期依赖关系，难以学习长程依赖。

RNN梯度爆炸

反过来，如果这串连乘中，每一步的放缩系数都偏大，那么乘很多次后就会迅速变大。

更直观地说：

* $\|U\| > 1$

* 某些方向上的特征值绝对值大于 1

那么多步相乘后：

$$\|\delta_{t,k}\| \rightarrow \infty$$

会导致：

- 参数更新过大
- 训练不稳定
- loss 震荡甚至变成 NaN

梯度消失/爆炸

梯度

$$\frac{\partial \mathcal{L}}{\partial U} = \sum_{t=1}^T \sum_{k=1}^t \delta_{t,k} \mathbf{h}_{k-1}^T$$

其中

$$\delta_{t,k} = \prod_{\tau=k}^{t-1} \underbrace{\left(\text{diag}(f'(\mathbf{z}_{\tau})) U^T \right)}_{\lambda} \delta_{t,t}$$

由于梯度爆炸或消失问题，实际上只能学习到短周期的依赖关系。这就是所谓的长程依赖问题。

长程依赖问题

循环神经网络在时间维度上非常深！

梯度消失或梯度爆炸

如何改进？

梯度爆炸问题

权重衰减

梯度截断

梯度消失问题

改进模型

长程依赖问题

改进方法

循环边改为线性依赖关系

$$\mathbf{h}_t = \mathbf{h}_{t-1} + g(\mathbf{x}_t; \theta),$$

强调的是：

- 旧状态直接传递
- 更新方式更简单
- 梯度更稳定

增加非线性

$$\mathbf{h}_t = \mathbf{h}_{t-1} + g(\mathbf{x}_t, \mathbf{h}_{t-1}; \theta),$$

强调的是：

- 在保留直接通路的基础上
- 再让更新项依赖当前输入和历史状态
- 提高表达能力


残差网络？

为了改善循环神经网络的长程依赖问题，一种非常好的解决方案是引入门控机制来控制信息的累积速度，包括有选择地加入新的信息，并有选择地遗忘之前累积的信息。这一类网络可以称为基于门控的循环神经网络（Gated RNN）。

长短期记忆网络（LSTM）
门控循环神经网络（GRU）

长短期记忆网络 (LSTM)

Long Short Term Memory networks (以下简称LSTMs)，一种特殊的RNN网络，该网络设计出来是为了解决长程依赖问题。



增加状态 c ，称为单元状态(cell state)，让它来保存长期的状态


长短期记忆网络（LSTM）

LSTM的关键，就是怎样控制长期状态 c 。LSTM使用三个控制开关：

第一个开关，负责控制如何继续保存长期状态 c ；


第二个开关，负责控制把即时状态输入到长期状态 c ；

第三个开关，负责控制是否把长期状态 c 作为当前的LSTM的输出；




长短期记忆网络 (LSTM)

标准RNN的重复模块



长短期记忆网络 (LSTM)


LSTM 的重复模块



除了 h 在随时间流动，单元状态 c 也在随时间流动，单元状态 c 就代表着长期记忆。

长短期记忆网络 (LSTM)



LSTM 的关键是单元状态，如水平线在图上方贯穿运行。



单元状态的传递类似于传送带，其直接在整个链上运行，中间只有一些少量的 线性交互，容易保存相关信息。

长短期记忆网络 (LSTM)

LSTM 通过精心设计的称作为“门” (gate) 的结构来去除或者增加单元状态中的信息。门是一种让信息选择式通过的方法。



此门包含一个 sigmoid 神经网络层和一个 pointwise 乘法操作

长短期记忆网络（LSTM）

LSTM用两个门来控制单元状态 c 的内容

- 遗忘门（forget gate），它决定了上一时刻的单元状态 c_{t-1} 有多少保留到当前时刻 c_t ；
 - 输入门（input gate），它决定了当前时刻网络的输入 x_t 有多少保存到单元状态 c_t 。
-
- LSTM用输出门（output gate）来控制单元状态 c_t 有多少输出到 LSTM的当前输出值 h_t

长短期记忆网络（LSTM）

理解 LSTM之遗忘门

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f) \quad (\text{式1})$$


上式中, W_f 是遗忘门的权重矩阵

$[h_{t-1}, x_t]$ 表示把两个向量连接成一个更长的向量

b_f 是遗忘门的偏置项, σ 是sigmoid函数

如果输入的维度是 d_x , 隐藏层的维度是 d_h , 单元状态的维度是 d_c ,

则遗忘门的权重矩阵 W_f 的维度是 $d_c \times (d_h + d_x)$



长短期记忆网络 (LSTM)

理解 LSTM之遗忘门


$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f)$$

$$\begin{aligned} [W_f] \begin{bmatrix} \mathbf{h}_{t-1} \\ \mathbf{x}_t \end{bmatrix} &= [W_{fh} \quad W_{fx}] \begin{bmatrix} \mathbf{h}_{t-1} \\ \mathbf{x}_t \end{bmatrix} \\ &= W_{fh} \mathbf{h}_{t-1} + W_{fx} \mathbf{x}_t \end{aligned}$$

权重矩阵 W_f 是两个矩阵拼接而来的,


一个是 W_{fh} , 它对应输入项 h_{t-1} 其维度为 $d_c \times d_h$

一个是 W_{fx} , 它对应这输入项 x_t , 其维度为 $d_c \times d_x$ 。



长短期记忆网络 (LSTM)

LSTM之输入门




$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i)$$
$$\tilde{C}_t = \tanh(W_C \cdot [h_{t-1}, x_t] + b_C)$$

sigmoid 函数称为输入门，决定将要更新什么值

tanh 层创建一个新的候选值向量, $\tilde{C}_t$ 会被加入到状态中

长短期记忆网络（LSTM）

LSTM之更新单元状态




$$C_t = f_t * C_{t-1} + i_t * \tilde{C}_t$$

现在开始计算当前时刻的单元状态 C_t 。它是由上一次的单元状态 C_{t-1} 按元素乘以遗忘门 f_t ，再用当前输入的单元状态 $\tilde{C}_t$ 按元素乘以输入门 i_t ，再将两个积加和产生的。

由于遗忘门的控制，它可以保存很久很久之前的信息，由于输入门的控制，它又可以避免当前无关紧要的内容进入记忆。

长短期记忆网络 (LSTM)

LSTM之输出门




$$o_t = \sigma(W_o [h_{t-1}, x_t] + b_o)$$

$$h_t = o_t * \tanh(C_t)$$

输出门控制了长期记忆对当前输出的影响，其由输出门和单元状态共同确定。

长短期记忆神经网络 (Long Short-Term Memory, LSTM)



$$\begin{aligned} i_t &= \sigma(W_i x_t + U_i h_{t-1} + b_i), & \tilde{c}_t &= \tanh(W_c x_t + U_c h_{t-1} + b_c) \\ f_t &= \sigma(W_f x_t + U_f h_{t-1} + b_f), & c_t &= f_t \odot c_{t-1} + i_t \odot \tilde{c}_t, \\ o_t &= \sigma(W_o x_t + U_o h_{t-1} + b_o), & h_t &= o_t \odot \tanh(c_t), \end{aligned}$$

门控循环神经网络（GRU）


GRU是LSTM的一种变体，它较LSTM网络的结构更加简单，而且效果也很好。LSTM引入了三个门函数：输入门、遗忘门和输出门来控制输入值、记忆值和输出值。而在GRU模型中只有两个门，分别是更新门和重置门。另外，GRU将单元状态与输出合并为一个状态 h 。

门控循环神经网络（GRU）

图中的 z_t 和 r_t 分别表示更新门和重置门。

更新门用于控制前一时刻的状态信息被带入到当前状态中的程度，更新门的值越大说明前一时刻的状态信息带入越多。

重置门控制前一状态有多少信息被写入到当前的候选集 $\tilde{h}_t$ 上，重置门越小，前一状态的信息被写入的越少。



$$z_t = \sigma(W_z \cdot [h_{t-1}, x_t])$$

$$r_t = \sigma(W_r \cdot [h_{t-1}, x_t])$$

$$\tilde{h}_t = \tanh(W \cdot [r_t * h_{t-1}, x_t])$$


$$h_t = (1 - z_t) * h_{t-1} + z_t * \tilde{h}_t$$

门控循环神经网络 (GRU)

$$\mathbf{h}_t = \mathbf{z}_t \odot \mathbf{h}_{t-1} + (1 - \mathbf{z}_t) \odot \tilde{\mathbf{h}}_t. \quad (6.69)$$

可以看出, 当 $\mathbf{z}_t = \mathbf{0}, \mathbf{r} = \mathbf{1}$ 时, GRU 网络退化为简单循环网络; 若 $\mathbf{z}_t = \mathbf{0}, \mathbf{r} = \mathbf{0}$ 时, 当前状态 $\mathbf{h}_t$ 只和当前输入 $\mathbf{x}_t$ 相关, 和历史状态 $\mathbf{h}_{t-1}$ 无关. 当 $\mathbf{z}_t = \mathbf{1}$ 时, 当前状态 $\mathbf{h}_t = \mathbf{h}_{t-1}$ 等于上一时刻状态 $\mathbf{h}_{t-1}$, 和当前输入 $\mathbf{x}_t$ 无关.

图6.8给出了 GRU 网络的循环单元结构.



RNN系列模型总结

简单 RNN

奠定循环结构基础，但受限于梯度消失问题，难以捕捉长距离的时间依赖关系。

LSTM 长短期记忆

引入门控机制与细胞状态，有效解决长期依赖，是目前处理序列数据的经典模型。

GRU 门控循环单元

简化 LSTM 结构，减少参数数量，训练效率更高，在多数场景下性能表现优异。



核心改进：从 RNN 到 LSTM/GRU，核心都是围绕如何通过门控机制更好地控制信息的流动、记忆与遗忘，从而解决长期依赖问题。

RNN要点

循环结构 (RNN)

通过共享参数和隐藏状态，打破了传统神经网络固定输入输出长度的限制，能够处理任意长度的序列数据。

梯度消失与爆炸

简单RNN在处理较长序列时，反向传播的梯度会呈指数级衰减或增长，导致模型无法学习到长期的依赖关系。

LSTM 门控机制

引入遗忘门、输入门和输出门，精细控制细胞状态的信息流动，有效解决了长期依赖问题，是序列建模的经典方案。

GRU 简化变体


将LSTM的门控和状态进行合并简化，减少了参数数量，在保持优异性能的同时，大幅提升了训练效率。



深层模型


堆叠循环神经网络

一种常见的增加循环神经网络深度的做法是将多个循环网络堆叠起来，称为堆叠循环神经网络。



双向循环神经网络

在有些任务中，一个时刻的输出不但和过去时刻的信息有关，也和后续时刻的信息有关。比如给定一个句子，其中一个词的词性由它的上下文决定，即包含左右两边的信息。因此，在这些任务中，我们可以增加一个按照时间的逆序来传递信息的网络层，来增强网络的能力。双向循环神经网络（Bidirectional Recurrent Neural Network, Bi-RNN）由两层循环神经网络组成，它们的输入相同，只是信息传递的方向不同





长短期记忆

记忆

短期记忆 (Short-term)

类比：电脑内存 (RAM)

定义：临时工作区，维持当前会话连贯性。

特点：临时、容量有限、实时性强。

实现：上下文窗口 (Context Window)。

长期记忆 (Long-term)

类比：电脑硬盘 (HDD)

定义：持久知识库，存储跨会话的信息。

特点：持久、容量大、可检索。

实现：外部存储（如向量数据库）。

双重记忆系统结合了实时交互能力与长期个性化服务，是AGI时代的关键架构。

短期记忆：对话的“即时记忆”

核心机制：上下文窗口

模型能同时处理的最大文本Token量，直接决定了短期记忆的容量上限。

关键技术：注意力机制

通过计算Token间相关性，选择性聚焦重要信息，避免信息过载。

挑战与局限

窗口容量有限导致早期信息丢失；注意力随距离衰减，远期信息关注度下降。

长期记忆：构建长程的“数字大脑”



核心实现方式：向量转化与检索

将用户偏好、历史对话等信息转化为向量（Embedding）存储于向量数据库，通过语义相似度检索，实现毫秒级相关信息匹配。



应用价值：RAG（检索增强）服务

结合长期记忆与通用知识库，为用户提供定制化回答。例如智能客服记住历史问题、电商系统精准推荐偏好商品，提升服务体验。

个性化记忆

什么是个性化记忆？

它是长期记忆的高级应用，专注存储用户偏好、行为习惯等独特信息，构建动态画像，从而实现个性化智能服务。

核心特点



多维用户画像

整合行为、偏好等多维度信息，形成全面认知



实时动态更新

基于最新交互反馈实时迭代，确保信息时效性



高度精准服务

基于画像提供定制化推荐、解答与决策支持

应用场景示例



智能电商推荐

分析用户浏览与购买历史，精准推送感兴趣的商品，提升购物体验与转化率。



自适应学习平台

根据学生的知识掌握情况和学习进度，动态调整学习内容，实现因材施教。



贴心智能客服

记住用户历史问题和偏好，无需重复说明，提供连贯、个性化的问题解决方案。



核心总结：记忆双引擎

短期记忆保障流畅的实时交互体验，长期记忆则为个性化服务奠定基础。两者的有机结合，是构建具备类人认知能力智能体的关键所在。



未来展望：自主与融合

未来的记忆系统将更智能，能自主决定记忆内容与优化检索策略。同时，实现文本、图像、音频等跨模态记忆的深度融合，让AI真正理解并记住多维世界。