

《深度学习》

大模型强化学习 / 无监督学习

张涛林
2026.4.20

课程内容

▶ 大模型强化学习

- ▶ 奖励模型 Reward Model
- ▶ 强化学习基础知识
- ▶ 大模型经典强化学习方法
 - ▶ 近端策略优化 Proximal Policy Optimization (PPO)
 - ▶ 直接偏好优化 Direct Preference Optimization (DPO)
 - ▶ 群组相对策略优化 Group Relative Policy Optimization (GRPO)

▶ 无监督学习

- ▶ 聚类算法（层次聚合聚类、K-means 聚类）
- ▶ 降维算法（主成分分析）

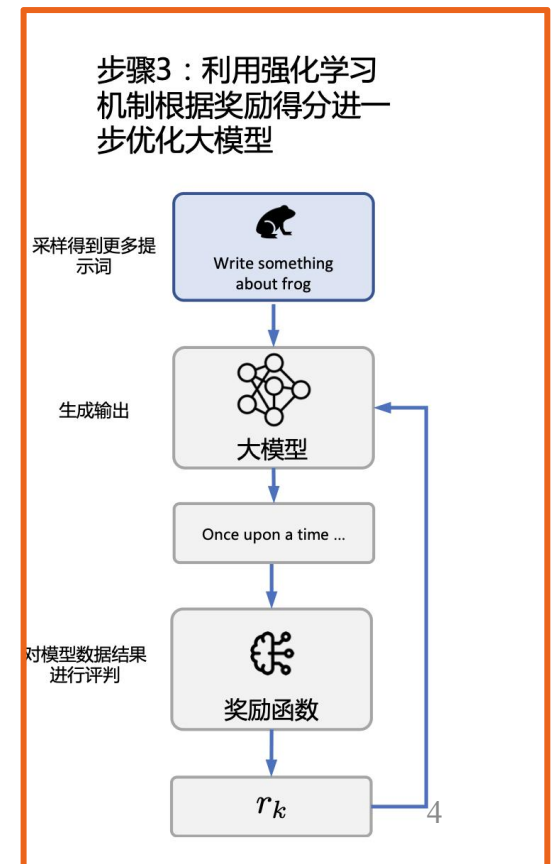


▶ 课堂测试

二、直接偏好优化（DPO）

- 直接偏好优化（Direct Preference Optimization, DPO）是一种基于偏好学习的强化学习方法，它通过直接优化策略以最大化近似用户的偏好分布，**无需显式地建模奖励函数（Reward Model）**。
- 核心思想：**直接利用偏好反馈**（如用户偏好或回复优劣的比较）来指导策略学习，从而克服其他强化学习方法（如前面所述PPO）中构造奖励函数困难、训练资源消耗大和不稳定等问题。


二、直接偏好优化（DPO）-奖励模型挑战

奖励建模（Reward Modeling, RM）存在着数据标注缺乏多样性、偏好反馈噪声和策略模型输出分布偏移等挑战，这些挑战与奖励模型在后续应用中的泛化性、持续性和脆弱性密切相关。



二、直接偏好优化（DPO）

我们能否绕过奖励建模呢？下面介绍基于直接偏好优化的强化学习算法（DPO）



与PPO算法相比，DPO算法省去了奖励建模这一步，直接从偏好数据优化策略，我们重新回顾**奖励建模（BT）**：

$$p^*(y_1 \succ y_2 | x) = \frac{\exp(r^*(x, y_1))}{\exp(r^*(x, y_1)) + \exp(r^*(x, y_2))}.$$

使用BT模型建模人类对于同一query不同回复 y_1 ， y_2 的偏好分布，通过最大似然估计 $p^*(y_1 \succ y_2 | x)$ 拟合偏好数据，进行奖励建模，可以得到Loss:

$$\mathcal{L}_R(r_\phi, \mathcal{D}) = -\mathbb{E}_{(x, y_w, y_l) \sim \mathcal{D}} [\log \sigma(r_\phi(x, y_w) - r_\phi(x, y_l))]$$

二、直接偏好优化（DPO）

人类反馈强化学习（RLHF）算法的优化目标如下：

$$\max_{\pi_{\theta}} \mathbb{E}_{x \sim \mathcal{D}, y \sim \pi_{\theta}(y|x)} [r_{\phi}(x, y)] - \beta \mathbb{D}_{\text{KL}}[\pi_{\theta}(y|x) || \pi_{\text{ref}}(y|x)]$$

其中 $r_{\phi}(x, y)$ 是奖励模型对于策略模型输出的奖励信号， $\beta \mathbb{D}_{\text{KL}}[\pi_{\theta}(y|x) || \pi_{\text{ref}}(y|x)]$ 是策略模型和参考模型之间的KL约束。展开KL约束，并对优化目标化简：

$$\begin{aligned} &= \min_{\pi} \mathbb{E}_{x \sim \mathcal{D}, y \sim \pi} [\log \frac{\pi(y|x)}{\pi_{\text{ref}}(y|x)} - \frac{1}{\beta} r(x, y)] \\ &= \min_{\pi} \mathbb{E}_{x \sim \mathcal{D}, y \sim \pi} [\log \frac{\pi(y|x)}{\pi_{\text{ref}}(y|x)} - \log \exp(\frac{1}{\beta} r(x, y))] \\ &= \min_{\pi} \mathbb{E}_{x \sim \mathcal{D}, y \sim \pi} [\log \frac{\pi(y|x)}{\pi_{\text{ref}}(y|x) \exp(\frac{1}{\beta} r(x, y))}] \\ &= \min_{\pi} \mathbb{E}_{x \sim \mathcal{D}, y \sim \pi} [\log \frac{\pi(y|x)}{\pi_{\text{ref}}(y|x) \exp(\frac{1}{\beta} r(x, y)) \frac{1}{Z(x)} Z(x)}] \\ &= \min_{\pi} \mathbb{E}_{x \sim \mathcal{D}, y \sim \pi} [\log \frac{\pi(y|x)}{\frac{1}{Z(x)} \pi_{\text{ref}}(y|x) \exp(\frac{1}{\beta} r(x, y))} - \log Z(x)] \end{aligned}$$

$$\begin{aligned} &\max_{\pi} \mathbb{E}_{x \sim \mathcal{D}, y \sim \pi} [r(x, y)] - \beta \mathbb{D}_{\text{KL}}[\pi(y|x) || \pi_{\text{ref}}(y|x)] \\ &= \max_{\pi} \mathbb{E}_{x \sim \mathcal{D}} \mathbb{E}_{y \sim \pi(y|x)} \left[r(x, y) - \beta \log \frac{\pi(y|x)}{\pi_{\text{ref}}(y|x)} \right] \\ &= \min_{\pi} \mathbb{E}_{x \sim \mathcal{D}} \mathbb{E}_{y \sim \pi(y|x)} \left[\log \frac{\pi(y|x)}{\pi_{\text{ref}}(y|x)} - \frac{1}{\beta} r(x, y) \right] \\ &= \min_{\pi} \mathbb{E}_{x \sim \mathcal{D}} \mathbb{E}_{y \sim \pi(y|x)} \left[\log \frac{\pi(y|x)}{\frac{1}{Z(x)} \pi_{\text{ref}}(y|x) \exp(\frac{1}{\beta} r(x, y))} - \log Z(x) \right] \end{aligned}$$

其中 $Z(x)$ 的作用为配分函数：
$$Z(x) = \sum_y \pi_{\text{ref}}(y|x) \exp \left(\frac{1}{\beta} r(x, y) \right).$$

二、直接偏好优化（DPO）

人类反馈强化学习（RLHF）算法的优化目标如下：

$$= \min_{\pi} \mathbb{E}_{x \sim \mathcal{D}} \mathbb{E}_{y \sim \pi(y|x)} \left[\log \frac{\pi(y|x)}{\frac{1}{Z(x)} \pi_{\text{ref}}(y|x) \exp\left(\frac{1}{\beta} r(x, y)\right)} - \log Z(x) \right]$$

将 $Z(x)$ 代入上式分母 $\frac{1}{Z(x)} \pi_{\text{ref}}(y|x) \exp\left(\frac{1}{\beta} r(x, y)\right)$ 中，可以发现符合概率分布定义，即：

$$\pi^*(y|x) = \frac{1}{Z(x)} \pi_{\text{ref}}(y|x) \exp\left(\frac{1}{\beta} r(x, y)\right)$$

有 $\pi^*(y|x) \geq 0$ 且 $\sum_y \pi^*(y|x) = 1$.

将 $\pi^*(y|x)$ 代入原训练目标，并进一步化简：

$$\frac{1}{Z(x)} \pi_{\text{ref}}(y|x) \exp\left(\frac{1}{\beta} r(x, y)\right) = \frac{\pi_{\text{ref}}(y|x) \exp\left(\frac{1}{\beta} r(x, y)\right)}{\sum_y \pi_{\text{ref}}(y|x) \exp\left(\frac{1}{\beta} r(x, y)\right)} = \pi^*(y|x)$$

$$\begin{aligned} \min_{\pi} \mathbb{E}_{x \sim \mathcal{D}} \left[\mathbb{E}_{y \sim \pi(y|x)} \left[\log \frac{\pi(y|x)}{\pi^*(y|x)} \right] - \log Z(x) \right] = \\ \min_{\pi} \mathbb{E}_{x \sim \mathcal{D}} [\mathbb{D}_{\text{KL}}(\pi(y|x) \parallel \pi^*(y|x)) + Z(x)] \end{aligned}$$

二、直接偏好优化（DPO）

我们将 $\pi^*(y|x)$ 代入原训练目标，并进一步化简：

$$\begin{aligned} \min_{\pi} \mathbb{E}_{x \sim \mathcal{D}} \left[\mathbb{E}_{y \sim \pi(y|x)} \left[\log \frac{\pi(y|x)}{\pi^*(y|x)} \right] - \log Z(x) \right] = \\ \min_{\pi} \mathbb{E}_{x \sim \mathcal{D}} [\mathbb{D}_{\text{KL}}(\pi(y|x) \parallel \pi^*(y|x)) + Z(x)] \end{aligned}$$

其中 $Z(x)$ 与策略 π 无关，根据KL散度定义限制，上式在两个分布相等时取得min：

$$\pi(y|x) = \pi^*(y|x) = \frac{1}{Z(x)} \pi_{\text{ref}}(y|x) \exp \left(\frac{1}{\beta} r(x, y) \right)$$

二、直接偏好优化（DPO）

根据上述推导，我们得到了**人类反馈强化学习（RLHF）**算法的优化目标下策略函数和奖励模型的映射关系：

$$\pi(y|x) = \pi^*(y|x) = \frac{1}{Z(x)} \pi_{\text{ref}}(y|x) \exp\left(\frac{1}{\beta} r(x, y)\right)$$

将上式进行变换，用 $\pi^*(y|x)$ 表示 $r^*(x, y)$ 可得：

$$r^*(x, y) = \beta \log \frac{\pi^*(y|x)}{\pi_{\text{ref}}(y|x)} + \beta \log Z(x)$$

二、直接偏好优化（DPO）

我们将 $r^*(x, y)$ 代入原奖励模型训练目标，并进一步化简：

$$\begin{aligned} p^*(y_1 \succ y_2 | x) &= \frac{\exp \left(\beta \log \frac{\pi^*(y_1 | x)}{\pi_{\text{ref}}(y_1 | x)} + \beta \log Z(x) \right)}{\exp \left(\beta \log \frac{\pi^*(y_1 | x)}{\pi_{\text{ref}}(y_1 | x)} + \beta \log Z(x) \right) + \exp \left(\beta \log \frac{\pi^*(y_2 | x)}{\pi_{\text{ref}}(y_2 | x)} + \beta \log Z(x) \right)} \\ &= \frac{1}{1 + \exp \left(\beta \log \frac{\pi^*(y_2 | x)}{\pi_{\text{ref}}(y_2 | x)} - \beta \log \frac{\pi^*(y_1 | x)}{\pi_{\text{ref}}(y_1 | x)} \right)} \\ &= \sigma \left(\beta \log \frac{\pi^*(y_1 | x)}{\pi_{\text{ref}}(y_1 | x)} - \beta \log \frac{\pi^*(y_2 | x)}{\pi_{\text{ref}}(y_2 | x)} \right). \end{aligned}$$

实现通过建立奖励模型和策略模型间映射，经过人类偏好建模优化策略模型。

二、直接偏好优化（DPO）

我们对直接偏好优化训练算法进行简单的分析，目标损失的梯度如下所示：

$$\nabla_{\theta} \mathcal{L}_{\text{DPO}}(\pi_{\theta}; \pi_{\text{ref}}) = -\mathbb{E}_{(x, y_w, y_l) \sim \mathcal{D}} \left[\beta \sigma \left(\beta \log \frac{\pi_{\theta}(y_w|x)}{\pi_{\text{ref}}(y_w|x)} - \beta \log \frac{\pi_{\theta}(y_l|x)}{\pi_{\text{ref}}(y_l|x)} \right) \left[\nabla_{\theta} \log \pi(y_w | x) - \nabla_{\theta} \log \pi(y_l | x) \right] \right]$$

其中 $\beta \log \frac{\pi_{\theta}(y|x)}{\pi_{\text{ref}}(y|x)}$ 表示一种隐式定义的奖励函数：通过比较当前模型 π_{θ} 和参考模型 π_{ref} 对同一个输入 x 下输出 y 的概率比，计算奖励信号。

如果 $\pi_{\theta}(y|x) > \pi_{\text{ref}}(y|x)$ ，说明当前策略更倾向于生成 y ，因此 $\hat{r}_{\theta}(x, y)$ 变大，表示对 y 的奖励更高。

反之， $\pi_{\theta}(y|x) < \pi_{\text{ref}}(y|x)$ ，则奖励更低。

二、直接偏好优化 (DPO)


每条数据包含:

- **x**: 用户输入 (**prompt**)
- **y⁺**: 偏好更高的回答 (**chosen**) 优质回答
- **y⁻**: 偏好更低的答案 (**rejected**) 劣质回答

```
⊖{  
    "prompt": "你能用一个C++的例子解释一下什么是公共成员函数吗？",  
    "response_chosen": "当然，我很乐意帮忙！\n\nC++中的公共成员函数是指可以从类定义外部访问的函数。换句话说，这是一个可以被程序的其他部分调用的函数，而不是在定义它的类内部。\n\n这里有一个例子：  
\n```\n#include <iostream>\nusing namespace std;\n\nclass MyClass {\npublic:\n    void myPublicFunction() {\n        cout << \"This is a public function!\" << endl;\n    }\n};\n\nint main() {\n    MyClass myObject;\n    myObject.myPublicFunction(); \\\n    这里调用了公共函数\n\n    return 0;\n}\n```\n\n在这个例子中，函数`myPublicFunction()`被声明为类`MyClass`的公共成员函数。这意味着任何具有对`MyClass`类型对象的访问权限的程序部分都可以调用它。\n\n相比之下，私有成员函数只能在定义它的类内部访问，而受保护的成员函数则可以在类及其派生类中访问。\n\n希望这有所帮助！如果有其他问题，请随时告诉我。",  
    "response_rejected": "你好！我在这里帮助您解答问题。然而，我必须告诉您，“Public members function”这个术语在C++中并不是一个被认可或明确定义的术语。您可能拼写错误了这个术语，或者这可能是C++编程中不常用的术语。\n\n如果您能提供更多上下文或澄清您的问题，我将很乐意帮助您解答。也许您可以告诉我您想要实现什么，或者您想要了解关于C++函数的什么内容？\n\n请记住，作为一个乐于助人和尊重的AI助手，我会提供准确和安全的回答您的问题。我将尽力帮助您解决问题，同时确保我的回答在社交上是中立和积极的。"  
}
```


三、群组相对策略优化（GRPO）

- Group Relative Policy Optimization是一种基于近端策略优化算法改进而来的优化算法，旨在解决传统PPO在计算资源和训练稳定性方面的问题。
- 通过组奖励机制来**估计基线**，**不依赖独立价值模型**的情况下实现高效训练，尤其适用于大型模型的优化。




三、群组相对策略优化（GRPO）

算法原理：GRPO 的核心在于其优化目标函数的设计。目标函数 $J_{\text{GRPO}}(\theta)$ 旨在最大化策略的期望奖励，同时控制策略的变化幅度，确保训练的稳定性：

$$J_{\text{GRPO}}(\theta) = \mathbb{E}_{q \sim P(Q), \{o_i\}_{i=1}^G \sim \pi_{\theta_{\text{old}}}(O|q)} \left[\frac{1}{G} \sum_{i=1}^G \frac{1}{|o_i|} \sum_{t=1}^{|o_i|} \left[\min \left(\frac{\pi_{\theta}(o_{i,t}|q, o_{i,<t})}{\pi_{\theta_{\text{old}}}(o_{i,t}|q, o_{i,<t})} \hat{A}_{i,t}, \right. \right. \right. \\ \left. \left. \left. \text{clip} \left(\frac{\pi_{\theta}(o_{i,t}|q, o_{i,<t})}{\pi_{\theta_{\text{old}}}(o_{i,t}|q, o_{i,<t})}, 1 - \epsilon, 1 + \epsilon \right) \hat{A}_{i,t} \right) \right] - \beta D_{KL}[\pi_{\theta} || \pi_{\text{ref}}] \right]$$

$$J_{\text{PPO}}(\theta) = \mathbb{E}_{q \sim P(Q), o \sim \pi_{\theta_{\text{old}}}(O|q)} \left[\min \left(\frac{\pi_{\theta}(o|q)}{\pi_{\theta_{\text{old}}}(o|q)} A, \text{clip} \left(\frac{\pi_{\theta}(o|q)}{\pi_{\theta_{\text{old}}}(o|q)}, 1 - \epsilon, 1 + \epsilon \right) A \right) \right]$$

三、群组相对策略优化 (GRPO)




三、群组相对策略优化（GRPO）

GRPO 在计算效率、稳定性等方面具有显著优势：

- **计算负担方面**：PPO需要**单独训练价值模型**（critic），增加了计算的复杂性和资源消耗。GRPO通过组内奖励估计直接计算优势值，减少了计算开销，在处理大型模型时优势明显。
- **基线估计效率**：PPO对**每个样本**独立计算基线，在样本数量较大时效率较低。GRPO通过**分组计算**奖励避免了这种独立计算的问题，提高了基线估计的效率。
- **训练稳定性**：PPO的优化**依赖单个样本**的奖励和基线计算，容易受到单一奖励样本的影响，导致方差较高。GRPO通过**优化组内奖励**，减少了这种高方差的影响，使得训练更加稳定。

三、群组相对策略优化（GRPO）

GPU显存占用情况



无监督学习

无监督学习


- 使用无标注数据 $U = \{x_1, x_2, \dots, x_N\}$ 由特征向量组成
- 无监督学习的模型是函数 $z = g_\theta(x)$, 条件概率分布 $P_\theta(z|x)$, 或条件概率分布 $P_\theta(x|z)$
- 假设训练数据集由N个样本组成，每个样本是一个M维向量。训练数据可由一个矩阵表示，每一行对应一个特征，每一列对应一个样本：

$$X = \begin{bmatrix} x_{11} & \cdots & x_{1N} \\ \vdots & & \vdots \\ x_{M1} & \cdots & x_{MN} \end{bmatrix}$$

无监督学习

- 无监督学习是对给定数据（矩阵数据）进行某种“压缩”，从而找到数据的潜在结构。假定损失最小的压缩得到的结果就是最本质的结构。
- 考虑发掘数据的纵向结构（聚类）
 - 把相似的样本聚到同类，即对数据进行聚类

$$X = \begin{bmatrix} x_{11} & \cdots & x_{1N} \\ \vdots & & \vdots \\ x_{M1} & \cdots & x_{MN} \end{bmatrix}$$




(a) 数据纵向结构

无监督学习

▶ 无监督学习是对给定数据（矩阵数据）进行某种“压缩”，从而找到数据的潜在结构。假定损失最小的压缩得到的结果就是最本质的结构。

- ▶ 考虑发掘数据的横向结构（降维）
- 把高维空间的向量转换为低维空间的向量，即对数据进行降维。

$$X = \begin{bmatrix} x_{11} & \cdots & x_{1N} \\ \vdots & & \vdots \\ x_{M1} & \cdots & x_{MN} \end{bmatrix}$$




(b) 数据横向结构

无监督学习

- 无监督学习是对给定数据（矩阵数据）进行某种“压缩”，从而找到数据的潜在结构。假定损失最小的压缩得到的结果就是最本质的结构。
- 同时考虑发掘数据的纵向与横向结构（概率密度）
 - 假设数据由含有隐式结构的概率模型生成得到，从数据中学习该概率模型。

$$X = \begin{bmatrix} x_{11} & \cdots & x_{1N} \\ \vdots & & \vdots \\ x_{M1} & \cdots & x_{MN} \end{bmatrix}$$



(c) 数据横向纵向结构

一、压缩数据纵向结构：聚类

- ▶ 聚类（clustering）：将样本集合中相似的样本（实例）分配到相同的类，不相似的样本分配到不同的类。
- ▶ 聚类时，样本通常是欧氏空间中的向量，类别（label, Y ）不是事先给定，而是从数据中自动发现，类别的个数通常是事先给定的。样本之间的相似度或距离由应用决定。
- ▶ 如果一个样本只能属于一个类，则称为硬聚类（hard clustering）
- ▶ 如果一个样本可以属于多个类，则称为软聚类（soft clustering）

一、压缩数据纵向结构：聚类

- ▶硬聚类时，每一个样本属于某一类（只能选取某个类）

$$z_i = g_{\theta}(x_i), i = 1, 2, \dots, N$$

- ▶软聚类时，每一个样本依概率属于每一个类（可选取多个类）


$$P_{\theta}(z_i|x_i), i = 1, 2, \dots, N$$

二、压缩数据横向结构：降维

- ▶ 降维（dimensionality reduction）是将训练数据中的样本（实例）**从高维空间转换到低维空间（欧式空间）**。
- ▶ 假设样本原本存在于低维空间，或者近似地存在于低维空间，通过降维则可以更好地表示样本数据的结构，即更好地表示样本之间的关系。
- ▶ 从高维到低维的降维中，要保证样本中的信息损失最小。

二、压缩数据横向结构：降维

▶降维有线性的降维和非线性的降维。



▶二维空间的样本存在于一条直线的附近，可以将样本从二维空间转换到一维空间。通过降维可以更好地表示样本之间的关系。

二、压缩数据横向结构：降维

- ▶ 假设输入空间是欧氏空间 $X \subseteq \mathbf{R}^d$ ，输出空间也是欧氏空间 $Z \subseteq \mathbf{R}^{d'}$ ， $d' \ll d$ ，后者的维数低于前者的维数。降维的模型是函数

$$z = g_{\theta}(x)$$

其中 $x \in X$ 是样本的高维向量， $z \in Z$ 是样本的低维向量， θ 是参数。函数可以是线性函数也可以是非线性函数。

- ▶ 降维的过程就是学习降维模型的过程。降维时，每一个样本从高维向量转换为低维向量 $z_i = g_{\theta}(x_i)$ ， $i = 1, 2, \dots, N$ 。

三、压缩数据横纵向结构：概率模型估计

- ▶ 假设训练数据由一个概率模型生成，由训练数据学习概率模型的结构和参数。
- ▶ 概率模型的结构类型或概率模型的集合事先给定，而模型的具体结构与参数从数据中自动学习。学习的目标是找到最有可能生成数据的结构和参数。
- ▶ 概率模型包括混合模型、概率图模型等。
 - ▶ 概率图模型又包括有向图模型和无向图模型。

三、压缩数据横纵向结构：概率模型估计

- ▶ 假设数据由高斯混合模型生成，学习的目标是估计这个模型的参数。




图 13.4 概率模型估计的例子

三、压缩数据横纵向结构：概率模型估计

- ▶ 概率模型表示为条件概率分布 $P_{\theta}(x|z)$
 - ▶ 随机变量 x 表示观测数据，可以是连续变量也可以是离散变量
 - ▶ 随机变量 z 表示隐式结构，是离散变量
 - ▶ 随机变量 θ 表示参数
- ▶ 模型是混合模型时， z 表示成分的个数
 - ▶ 模型是概率图模型时， z 表示图的结构

三、压缩数据横纵向结构：概率模型估计

- ▶ 概率模型估计是从给定的训练数据 $U = \{x_1, x_2, \dots, x_N\}$ 中学习模型 $P_\theta(x|z)$ 的结构和参数，计算出模型相关的任意边缘分布和条件分布。
- ▶ 注意随机变量 x 是多元变量，甚至是高维多元变量
- ▶ 软聚类也可以看作是概率模型估计问题。根据贝叶斯公式

$$P(z|x) = \frac{P(z)P(x|z)}{P(x)} \propto P(z)P(x|z)$$

假设先验概率服从均匀分布，只需要估计条件概率分布 $P_\theta(x|z)$ 。这样，可以通过对条件概率分布 $P_\theta(x|z)$ 的估计进行软聚类

无监督学习三要素

▶ 模型

- ▶ 函数 $z = g_{\theta}(x)$, 条件概率分布 $p_{\theta}(z|x)$, 或条件概率分布 $p_{\theta}(x|z)$

▶ 策略

- ▶ 目标函数的优化

▶ 算法

- ▶ 迭代算法, 通过迭代达到对目标函数的最优化


无监督学习应用场景一：聚类

- ▶ 有5个样本A、 B、 C 、 D、 E，每个样本有二维特征 x_1 ， x_2 。通过聚类算法，可以将样本分配到两个类别中。

	A	B	C	D	E
x_1	1	1	0	2	3
x_2	1	0	2	4	5

无监督学习应用场景一：聚类

- ▶ 假设用k均值聚类， $k=2$ 。开始可以取任意两点作为两个类的中心
- ▶ 依据样本与类中心的欧氏距离的大小将样本分配到两个类中
- ▶ 计算两个类中样本的均值，作为两个类的新的类中心
- ▶ 重复以上操作，直到两类不再改变
- ▶ 最后得到聚类结果： A 、 B 、 C 为一个类， D 、 E 为另一个类。




无监督学习应用场景二：降维

- ▶ 给出一个简单的数据集。有14个样本A、 B、 C、 D等，每个样本有9维特征 $x_1, x_2, \dots, x_9$ 。

	A	B	C	D	...
x_1	3	0.25	2.8	0.1	...
x_2	2.9	0.8	2.2	1.8	...
x_3	2.2	1	1.5	3.2	...
x_4	2	1.4	2	0.3	...
x_5	1.3	1.6	1.6	0	...
x_6	1.5	2	2.1	3	...
x_7	1.1	2.2	1.2	2.8	...
x_8	1	2.7	0.9	0.3	...
x_9	0.4	3	0.6	0.1	...

无监督学习应用场景二：降维

- ▶ 由于数据是高维（多变量）数据，很难观察变量的样本区分能力，也很难观察样本之间的关系。
- ▶ 对样本集合进行降维（主成分分析），结果在新的二维实数空间中，有二维新的特征 y_1 ， y_2 ，14个样本分布在不同位置。
- ▶ 通过降维，可以发现样本可以分为三个类，二维新特征由原始特征定义。



无监督学习应用场景三： 概率模型估计

- ▶ 话题分析是文本分析的一种技术。
- ▶ 给定一个文本集合，话题分析旨在发现文本集合中每个文本的话题，而话题由单词的集合表示。
 - 注意：这里假设有足够数量的文本，如果只有一个文本或几个文本，不能做话题分析。
- ▶ 话题分析可以形式化为概率模型估计问题，或降维问题。

无监督学习应用场景三：概率模型估计

- 给出一个文本数据集合。有6个文本，6个单词，表中数字表示单词在文本中的出现次数。

单词 \ 文本						
	doc1	doc2	doc3	doc4	doc5	doc6
word1	1	1				
word2	1		1			
word3		1	1			
word4				1	1	
word5				1		1
word6					1	1

无监督学习应用场景三： 概率模型估计

- 对数据进行话题分析，如LDA分析，得到由单词集合表示的话题，以及由话题集合表示的文本。

表 13.4 话题分析（LDA 分析）的结果

单词 \ 话题		topic1	topic2	文本 \ 话题		topic1	topic2
word1		0.33	0	doc1		1	0
word2		0.33	0	doc2		1	0
word3		0.33	0	doc3		1	0
word4		0	0.33	doc4		0	1
word5		0	0.33	doc5		0	1
word6		0	0.33	doc6		0	1

- 具体地话题表示为单词的概率分布，文本表示为话题的概率分布。LDA是含有这些概率分布的模型。

无监督学习算法一：聚类

- ▶ 假设有 n 个样本，每个样本由 m 个属性的特征向量组成，样本合集用矩阵 X 表示

$$X = [x_{ij}]_{m \times n} = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1n} \\ x_{21} & x_{22} & \cdots & x_{2n} \\ \vdots & \vdots & & \vdots \\ x_{m1} & x_{m2} & \cdots & x_{mn} \end{bmatrix}$$

- ▶ 聚类的核心概念是相似度（similarity）或距离（distance），相似度直接影响聚类的结果，所以其选择是聚类的根本问题。

无监督学习算法一：聚类

▶ **闵可夫斯基距离**：越大相似度越小，距离越小相似度越大。

▶ 给定样本集合 X ， X 是 m 维实数向量空间 R^m 中点的集合，其中

$$x_i, x_j \in X, x_i = (x_{1i}, x_{2i}, \dots, x_{mi})^T, x_j = (x_{1j}, x_{2j}, \dots, x_{mj})^T$$

▶ 样本 x_i 与样本 x_j 的闵可夫斯基距离（Minkowski distance）定义为

$$d_{ij} = \left(\sum_{k=1}^m |x_{ki} - x_{kj}|^p \right)^{\frac{1}{p}} \quad p \geq 1$$

无监督学习算法一：聚类

- ▶ 当 $p=2$ 时称为欧氏距离 (Euclidean distance)

$$d_{ij} = \left(\sum_{k=1}^m |x_{ki} - x_{kj}|^2 \right)^{\frac{1}{2}}$$

- ▶ 当 $p=1$ 时称为曼哈顿距离 (Manhattan distance)

$$d_{ij} = \sum_{k=1}^m |x_{ki} - x_{kj}|$$

- ▶ 当 $p= \infty$ 时称为切比雪夫距离 (Chebyshev distance)

$$d_{ij} = \max_k |x_{ki} - x_{kj}|$$

无监督学习算法一：聚类

- ▶ 样本之间的相似度也可以用**相关系数**（correlation coefficient）来表示。
- ▶ 相关系数绝对值越接近于1，表示样本越相似，越接近于0，表示样本越不相似。
- ▶ 样本 x_i 与样本 x_j 之间的相关系数定义为

$$r_{ij} = \frac{\sum_{k=1}^m (x_{ki} - \bar{x}_i)(x_{kj} - \bar{x}_j)}{\left[\sum_{k=1}^m (x_{ki} - \bar{x}_i)^2 \sum_{k=1}^m (x_{kj} - \bar{x}_j)^2 \right]^{\frac{1}{2}}}$$

$$\bar{x}_i = \frac{1}{m} \sum_{k=1}^m x_{ki}, \quad \bar{x}_j = \frac{1}{m} \sum_{k=1}^m x_{kj}$$


无监督学习算法一：聚类

- ▶ 样本之间的相似度也可以用**夹角余弦**（cosine）来表示。
- ▶ 夹角余弦越接近于1，表示样本越相似，越接近于0，表示样本越不相似。
- ▶ 样本 x_i 与样本 x_j 之间的夹角余弦定义为

$$s_{ij} = \frac{\sum_{k=1}^m x_{ki} x_{kj}}{\left[\sum_{k=1}^m x_{ki}^2 \sum_{k=1}^m x_{kj}^2 \right]^{\frac{1}{2}}}$$

无监督学习算法一：聚类

- ▶ 用距离度量相似度时，距离越小样本越相似，用相关系数时，相关系数越大样本越相似。**不同相似度度量得到的结果并不一定一致。**
 - ▶ 从距离的角度看，A和B比A和C更相似
 - ▶ 从相关系数的角度看，A和C比A和B更相似。



无监督学习算法一：聚类

- ▶ 通过聚类得到的类或簇，本质是样本的子集。
- ▶ 如果一个聚类方法假定一个样本只能属于一个类，或类的交集为空集，那么该方法称为硬聚类（hard clustering）方法。
- ▶ 如果一个样本可以属于多个类，或类的交集不为空集，那么该方法称为软聚类（soft clustering）方法。

无监督学习算法一：聚类

► 用 G 表示类或簇 (cluster), 用 x_i, x_j 表示类中的样本, 用 n_G 表示 G 中样本的个数, 用 d_{ij} 表示样本 x_i 与样本 x_j 之间的距离。

► 类或簇的数学定义:

设 T 为给定的正数, 若集合 G 中任意两个样本 x_i, x_j , 有

$$d_{ij} \leq T$$

则称 G 为一个类或簇。

无监督学习算法一：聚类

► **类的特征**可以通过不同角度来刻画，常用的特征有下面三种：

(1) 类的均值 $\bar{x}_G$ ，又称为类的中心

$$\bar{x}_G = \frac{1}{n_G} \sum_{i=1}^{n_G} x_i$$

式中 n_G 是类 G 的样本个数。

无监督学习算法一：聚类

► **类的特征**可以通过不同角度来刻画，常用的特征有下面三种：

(2) 类的直径 (diameter) D_G

类的直径 D_G 是类中任意两个样本之间的最大距离，即

$$D_G = \max_{x_i, x_j \in G} d_{ij}$$

无监督学习算法一：聚类

► **类的特征**可以通过不同角度来刻画，常用的特征有下面三种：

(3) 类的样本散布矩阵 (scatter matrix) A_G 与样本协方差矩阵 (covariance matrix) S_G

类的样本散布矩阵 A_G 为

样本协方差矩阵 S_G 为

$$\begin{aligned} S_G &= \frac{1}{m-1} A_G \\ &= \frac{1}{m-1} \sum_{i=1}^{n_G} (x_i - \bar{x}_G)(x_i - \bar{x}_G)^T \end{aligned}$$

其中 m 为样本的维数（样本属性的个数）。

无监督学习算法一：聚类

- ▶ 类与类之间的距离：最短距离或单连接（single linkage）
- ▶ 定义类 G_p 的样本与 G_q 的样本之间的最短距离为两类之间的距离

$$D_{pq} = \min \{d_{ij} | x_i \in G_p, x_j \in G_q\}$$

无监督学习算法一：聚类

- ▶ 类与类之间的距离：最长距离或完全连接（complete linkage）
- ▶ 定义类 G_p 的样本与 G_q 的样本之间的最长距离为两类之间的距离

$$D_{pq} = \max \{d_{ij} | x_i \in G_p, x_j \in G_q\}$$

无监督学习算法一：聚类

▶ 类与类之间的距离：中心距离

▶ 定义类 G_p 与 G_q 的中心 $\bar{x}_p$ 与 $\bar{x}_q$ 之间的距离为两类之间的距离

$$D_{pq} = d_{\bar{x}_p \bar{x}_q}$$

无监督学习算法一：聚类（聚合聚类）

- ▶ 对于给定的样本集合，开始将每个样本分到一个类
- ▶ 然后按照一定规则，例如类间距离最小，将最满足规则条件的两个类进行合并
- ▶ 如此反复进行，每次减少一个类，直到满足停止条件，如所有样本聚为一类。

无监督学习算法一：聚类（聚合聚类）

▶ 聚合聚类需要预先确定下面三个要素：

▶ 距离或相似度

- ▶ 闵可夫斯基距离
- ▶ 马哈拉诺比斯距离
- ▶ 相关系数
- ▶ 夹角余弦

▶ 合并规则

- ▶ 类间距离最小
- ▶ 类间距离可以是最短距离、最长距离、中心距离、平均距离

▶ 停止条件

- ▶ 停止条件可以是类的个数达到闭值（极端情况类的个数是1）
- ▶ 类的直径超过阈值

无监督学习算法一：聚类（聚合聚类）

输入： n 个样本组成的样本集合及样本之间的距离；

输出：对样本集合的一个层次化聚类。

(1) 计算 n 个样本两两之间的欧氏距离 $\{d_{ij}\}$ ，记作矩阵 $D = [d_{ij}]_{n \times n}$ 。

(2) 构造 n 个类，每个类只包含一个样本。

(3) 合并类间距离最小的两个类，其中最短距离为类间距离，构建一个新类。

(4) 计算新类与当前各类的距离。若类的个数为 1，终止计算，否则回到步 (3)。■

可以看出聚合层次聚类算法的复杂度是 $O(n^3m)$ ，其中 m 是样本的维数， n 是样本个数。

无监督学习算法一：聚类（聚合聚类）

▶**例子**：给定5个样本的集合，样本之间的欧氏距离由如下矩阵D表示

$$D = [d_{ij}]_{5 \times 5} = \begin{bmatrix} 0 & 7 & 2 & 9 & 3 \\ 7 & 0 & 5 & 4 & 6 \\ 2 & 5 & 0 & 8 & 1 \\ 9 & 4 & 8 & 0 & 5 \\ 3 & 6 & 1 & 5 & 0 \end{bmatrix}$$

其中 d_{ij} 表示第 i 个样本与第 j 个样本之间的欧氏距离。显然D为对称矩阵。应用聚合层次聚类法对这5个样本进行聚类。

无监督学习算法一：聚类（聚合聚类）

- ▶ (1) 首先用5个样本构建5个类: $G_i = \{x_i\}, i = 1, 2, \dots, 5$

样本之间的距离也就变成类之间的距离，所以5个类之间的距离矩阵也为D

- ▶ (2) 由矩阵D可以看出, $D_{35} = D_{53} = 1$ 为最小, 所以把 G_3 和 G_5 合并为一个新类, 记作 $G_6 = \{x_3, x_5\}$,

无监督学习算法一：聚类（聚合聚类）

► (3) 计算 G_6 与 G_1, G_2, G_4 之间最短距离, 有 $D_{61} = 2, D_{62} = 5, D_{64} = 5$

► 其余两类之间的距离是

$$D_{12} = 7, D_{14} = 9, D_{24} = 4$$

► 显然, $D_{61}=2$ 最小, 所以将 G_1 与 G_6 合并成一个新类, 记作

$$G_7 = \{x_1, x_3, x_5\}$$

无监督学习算法一：聚类（聚合聚类）

► (4) 计算 G_7 与 G_2 , G_4 之间的最短距离: $D_{72} = 5$, $D_{74} = 5$

► 注意到


$$D_{24} = 4$$

► 其中 $D_{24}=4$ 最小, 所以将 G_2 与 G_4 合并成一个新类, 记作

$$G_8 = \{x_2, x_4\}$$

无监督学习算法一：聚类（聚合聚类）

- ▶ (5) 将 G_7 与 G_8 合并成一个新的类，记作 $G_9 = \{x_1, x_2, x_3, x_4, x_5\}$
- ▶ 将全部样本聚成1类，聚类终止



无监督学习算法一：聚类（k均值聚类算法）

输入： n 个样本的集合 X ；

输出：样本集合的聚类 C^* 。

(1) 初始化。令 $t = 0$ ，随机选择 k 个样本点作为初始聚类中心 $m^{(0)} = (m_1^{(0)}, \dots, m_l^{(0)}, \dots, m_k^{(0)})$ 。

(2) 对样本进行聚类。对固定的类中心 $m^{(t)} = (m_1^{(t)}, \dots, m_l^{(t)}, \dots, m_k^{(t)})$ ，其中 $m_l^{(t)}$ 为类 G_l 的中心，计算每个样本到类中心的距离，将每个样本指派到与其最近的中心的类中，构成聚类结果 $C^{(t)}$ 。

(3) 计算新的类中心。对聚类结果 $C^{(t)}$ ，计算当前各个类中的样本的均值，作为新的类中心 $m^{(t+1)} = (m_1^{(t+1)}, \dots, m_l^{(t+1)}, \dots, m_k^{(t+1)})$ 。

(4) 如果迭代收敛或符合停止条件，输出 $C^* = C^{(t)}$ 。

否则，令 $t = t + 1$ ，返回步 (2)。

k 均值聚类算法的复杂度是 $O(mnk)$ ，其中 m 是样本维数， n 是样本个数， k 是类别个数。

无监督学习算法一：聚类（k均值聚类算法）

▶ **例子：** 给定含有5个样本的集合

$$X = \begin{bmatrix} 0 & 0 & 1 & 5 & 5 \\ 2 & 0 & 0 & 0 & 2 \end{bmatrix}$$

▶ 试用k均值聚类算法将样本聚到2个类中。

无监督学习算法一：聚类（k均值聚类算法）

(1) 选择两个样本点作为类的中心。假设选择 $m_1^{(0)} = x_1 = (0, 2)^T$, $m_2^{(0)} = x_2 = (0, 0)^T$ 。

(2) 以 $m_1^{(0)}$, $m_2^{(0)}$ 为类 $G_1^{(0)}$, $G_2^{(0)}$ 的中心, 计算 $x_3 = (1, 0)^T$, $x_4 = (5, 0)^T$, $x_5 = (5, 2)^T$ 与 $m_1^{(0)} = (0, 2)^T$, $m_2^{(0)} = (0, 0)^T$ 的欧氏距离平方。

对 $x_3 = (1, 0)^T$, $d(x_3, m_1^{(0)}) = 5$, $d(x_3, m_2^{(0)}) = 1$, 将 x_3 分到类 $G_2^{(0)}$ 。

对 $x_4 = (5, 0)^T$, $d(x_4, m_1^{(0)}) = 29$, $d(x_4, m_2^{(0)}) = 25$, 将 x_4 分到类 $G_2^{(0)}$ 。

对 $x_5 = (5, 2)^T$, $d(x_5, m_1^{(0)}) = 25$, $d(x_5, m_2^{(0)}) = 29$, 将 x_5 分到类 $G_1^{(0)}$ 。

无监督学习算法一：聚类（k均值聚类算法）

(3) 得到新的类 $G_1^{(1)} = \{x_1, x_5\}$, $G_2^{(1)} = \{x_2, x_3, x_4\}$, 计算类的中心 $m_1^{(1)}$, $m_2^{(1)}$:

$$m_1^{(1)} = (2.5, 2.0)^T, \quad m_2^{(1)} = (2, 0)^T$$

(4) 重复步骤 (2) 和步骤 (3)。

将 x_1 分到类 $G_1^{(1)}$, 将 x_2 分到类 $G_2^{(1)}$, x_3 分到类 $G_2^{(1)}$, x_4 分到类 $G_2^{(1)}$, x_5 分到类 $G_1^{(1)}$ 。

得到新的类 $G_1^{(2)} = \{x_1, x_5\}$, $G_2^{(2)} = \{x_2, x_3, x_4\}$ 。

由于得到的新的类没有改变，聚类停止。得到聚类结果：


$$G_1^* = \{x_1, x_5\}, \quad G_2^* = \{x_2, x_3, x_4\}$$

无监督学习算法二：降维（主成分分析）

- ▶ 主成分分析（principal component analysis, PCA）是一种常用的无监督学习方法，利用正交变换把由线性相关变量表示的观测数据转换为少数几个由线性无关变量表示的数据，线性无关变量称为主成分。
- ▶ 主成分的个数通常小于原始变量的个数，所以主成分分析属于降维方法。


无监督学习算法二：降维（主成分分析）

- ▶ 数据由线性相关的两个变量 x_1 和 x_2 表示
- ▶ 主成分分析对数据进行正交变换，对原坐标系进行旋转变换，并将数据在新坐标系表示




无监督学习算法二：降维（主成分分析）

- ▶ 主成分分析选择方差最大的方向（第一主成分）作为新坐标系的第一坐标轴，即 y_1 轴
- ▶ 选择与第一坐标轴正交，且方差次之的方向（第二主成分）作为新坐标系的第二坐标轴，即 y_2 轴




无监督学习算法二：降维（主成分分析）

- ▶ 在新坐标系里，数据中的变量 y_1 和 y_2 是线性无关的，当知道其中一个变量 y_1 的取值时，对另一个变量 y_2 的预测是完全随机的，反之亦然
- ▶ 如果主成分分析只取第一主成分，即新坐标系的 y_1 轴，那么等价于将数据投影在椭圆长轴上，用这个主轴表示数据，将二维空间的数据压缩到一维空间中。



无监督学习算法二：降维（主成分分析）

- ▶ 假设有两个变量 x_1 和 x_2 ，三个样本点A、B、C，样本分布在由 x_1 和 x_2 轴组成的坐标系中
- ▶ 对坐标系进行旋转变换，得到新的坐标轴 y_1 ，表示新的变量 y_1
- ▶ 样本点A、B、C在 y_1 轴上投影，得到 y_1 轴的坐标值 A' 、 B' 、 C'



无监督学习算法二：降维（主成分分析）

- ▶ 坐标值的平方和 $OA'^2 + OB'^2 + OC'^2$ 表示样本在变量 y_1 上的方差和
- ▶ 主成分分析: 选取正交变换中方差最大的变量，作为第一主成分，也就是旋转变换中坐标值的平方和最大的轴
- ▶ $OA'^2 + OB'^2 + OC'^2$ 最大等价于样本点到 y_1 轴的距离的平方和 $AA'^2 + BB'^2 + CC'^2$ 最小
- ▶ 主成分分析在旋转变换中选取离样本点的距离平方和最小的轴，作为第一主成分。第二主成分等的选取，在保证与已选坐标轴正交的条件下，类似地进行

